



Département de génie informatique et génie logiciel

Cours INF8770:

Technologies multimédias

TP3 - Détection de Prises de Vues et Images-Clefs

Équipe A49

Noms et matricules :

Ireina Hedad (2213673)

Arman Lidder (2174916)

Date de remise :

Le 20 avril 2026

Table des matières :

Partie 1 — Problématique, Analyse et Conception.....	1
Question 1 : Analyse des Données et Identification des Défis (/4).....	1
Question 2 : Conception et Justification de la Solution (/4).....	3
2.1 Méthode de détection choisie et justification.....	3
2.2 Stratégie de sélection des images-clefs par K-Moyennes.....	4
Partie 2 — Implémentation Logicielle et Paramétrage.....	4
Question 3 : Développement de la Solution Adaptative (/6).....	4
3.1 Architecture du pipeline.....	4
3.2 Sensibilité aux seuils	5
Question 4 : Mosaïques et Performances (/3).....	6
Question 5 : Analyse Critique du Modèle (/3).....	8
5.1 Évaluation globale	8
5.2 Cas d'échec résiduels et incertitudes.....	8
5.3 Universalité du seuil et recommandations.....	9

Partie 1 — Problématique, Analyse et Conception

Question 1 : Analyse des Données et Identification des Défis (/4)

Le tableau ci-dessous résume les caractéristiques techniques des trois extraits vidéo analysés.

	Vidéo 1 — F1 Abu Dhabi	Vidéo 2 — Game of Thrones	Vidéo 3 — Star Wars
Résolution	854×480	1920×1080	1920×1080
Fréquence d'images (FPS)	25 fps	30 fps	29.97 fps
Nombre de transitions	16	18	1
Fenêtre d'évaluation	~85 s	~45 s	~9 s
Type de contenu	Sport rapide, overlays TV	Scène de nuit, effets de feu	Texte défilant, fond statique
Type de transitions	Coupures nettes, transitions en deux temps	Coupures nettes	Une seule coupure franche

Vidéo 1 — Abu Dhabi Grand Prix 2021

On retrouve dans cette vidéo des ralentis, des replays et des transitions entre angles de caméra. Les voitures traversent le cadre en une fraction de seconde, rendant la différence entre deux trames consécutives massivement élevée sans qu'il y ait de véritable coupure de scène. Une fonction naïve interprétera ces pics comme des fausses coupures. Le flou cinétique accentue ce problème en rendant les contours indéfinis entre trames consécutives.

On peut également repérer des fondus enchaînés, ce qui complique la détection du point exact de coupure : la différence entre trames augmente graduellement plutôt que brusquement, risquant de passer sous le seuil de détection. Un défi supplémentaire est la présence de transitions en deux temps, où une coupure vers une frame quasi-noire contenant du texte précède une nouvelle scène, générant deux pics rapprochés au lieu d'un seul et risquant de produire des faux positifs ou de faire rater la vraie transition. Enfin, les incrustations graphiques (noms de pilotes, classements, chrono) créent un pic de différence localisé lorsqu'elles apparaissent ou disparaissent brusquement, pouvant être confondu avec une coupure.

La vidéo est encodée à 25 fps en 854×480. À ce framerate, certaines transitions très courtes n'occupent que quelques trames, les rendant difficiles à distinguer du bruit de mouvement. Un seuil non normalisé par le nombre de pixels restera sensible aux variations d'échelle.

Vidéo 2 — Game of Thrones : Dothraki vs Army of the Dead

On voit dans cette deuxième vidéo une scène de nuit presque intégralement sombre, avec des effets de feu, de fumée et des mouvements de foule chaotiques. Les éclairs de feu provoquent des variations brutales de luminosité sur l'ensemble du cadre en une ou deux trames, faisant exploser momentanément la différence globale entre trames et simulant une coupure là où il n'y en a pas. Inversement, dans les zones très sombres, deux prises de vues distinctes peuvent produire des histogrammes quasi-identiques, causant des coupures manquées puisque la différence reste sous le seuil de détection.

Les effets de particules (fumée, feu) génèrent un bruit visuel haute fréquence constant qui pollue le signal de différence et complique la distinction entre un vrai changement de scène et du mouvement intra-scène.

La vidéo est encodée à 30 fps en 1920×1080. À haute résolution, la somme brute des différences entre trames est plus grande, ce qui signifie qu'un seuil non normalisé par le nombre de pixels sera plus facilement franchi par le bruit visuel, augmentant le risque de faux positifs.

Vidéo 3 — Star Wars Episode III : Opening Crawl

Cette vidéo présente un texte défilant sur un fond d'étoiles quasi-statique, suivi d'un mouvement de caméra lent vers un soleil en arrière-plan. Elle ne contient qu'une seule vraie coupure, à 9 secondes, entre l'écran noir initial et le logo Star Wars.

Le défilement continu du texte produit une différence inter-trames faible mais constante, créant un bruit de fond qui peut élever artificiellement le seuil et masquer la vraie coupure. Le fond étoilé génère également un léger bruit de compression vidéo qui s'accumule trame après trame, contribuant à ce plancher de différence résiduelle.

Le principal piège est le mouvement de caméra vers le soleil en fin de séquence : la luminosité passe progressivement du noir profond à un orange vif, ce qui fait augmenter graduellement la différence entre trames et peut être confondu avec un fondu ou une coupure par un algorithme naïf, alors qu'il n'y a aucune transition réelle.

La vidéo est encodée à 29.97 fps en 1920×1080. À haute résolution, le bruit de compression sur le fond étoilé affecte davantage de pixels, polluant le signal de différence. Le framerate standard ne pose pas de défi particulier, mais la combinaison mouvement lent + haute résolution rend le seuil de détection plus sensible au bruit.

Question 2 : Conception et Justification de la Solution (/4)

2.1 Méthode de détection choisie et justification

Face aux défis identifiés dans les trois vidéos, la méthode que nous proposons repose sur une comparaison d'histogrammes de couleur locaux, combinée à un seuillage adaptatif. Le cours présente une approche à deux seuils fixes t_b et t_s pour distinguer coupures nettes et fondus. Nous remplaçons ces seuils statiques par un seuillage adaptatif calculé dynamiquement, ce qui permet de s'ajuster automatiquement à des vidéos au contenu aussi différent que les trois extraits fournis. Plutôt que de comparer chaque pixel individuellement, on divise chaque trame en une grille de zones locales. Pour chaque bloc, on calcule un histogramme de couleur et on compare ensuite les histogrammes de la trame actuelle avec ceux de la trame précédente à l'aide d'une métrique de distance. La différence finale est la moyenne pondérée des distances locales sur tous les blocs. Le seuillage adaptatif consiste à calculer dynamiquement le seuil de détection sur une fenêtre glissante de N trames, en utilisant la moyenne et l'écart-type des différences récentes. Une coupure est détectée seulement si la différence dépasse $\text{moyenne} + k \times \text{écart-type}$ (k typiquement entre 2 et 3).

Cette approche se distingue de la différence pixel-à-pixel, de l'histogramme global à seuil fixe décrit dans le cours, et de la méthode basée sur les arêtes pour les raisons suivantes. En effet, la comparaison par histogrammes est naturellement robuste aux petits décalages spatiaux (mouvement de caméra, flou cinétique), car elle capte la distribution globale des couleurs dans une zone plutôt que la position exacte de chaque pixel. Les mouvements rapides des voitures F1 ne feront donc pas exploser la métrique inutilement. De plus, découper la trame en blocs locaux permet de détecter des transitions partielles. L'espace HSV sépare la luminosité (V) de la couleur (H , S). Cela permet de mieux gérer les flashes lumineux de la vidéo *Game of Thrones* : une explosion de feu modifie fortement V mais pas nécessairement H , ce qui limite les faux positifs. On pourrait également pondérer les canaux différemment selon le contenu. Également, un seuil fixe échoue inévitablement face à des vidéos aussi différentes entre elles et entre ces trames. La scène nocturne de la deuxième vidéo a un niveau de bruit très différent du *crawl* *Star Wars*. Le seuillage adaptatif s'ajuste automatiquement au contexte local de chaque vidéo, réduisant à la fois les faux positifs (flashes de feu) et les coupures manquées (fondus progressifs). Finalement, la détection par arêtes (filtres Sobel) est coûteuse en calcul à 1920×1080 et moins robuste aux changements de luminosité globale comme les flashes de feu de *GoT*, qui modifient l'intensité de l'image entière sans introduire de nouvelles arêtes structurelles.

2.2 Stratégie de sélection des images-clefs par K-Moyennes

Une fois les prises de vue détectées (les segments entre deux coupures), il faut sélectionner les images-clefs les plus représentatives de chaque segment. Nous proposons d'utiliser la méthode des K-Means. Pour chaque prise de vue détectée, on extrait un descripteur visuel compact pour chaque trame du segment. On applique ensuite K-Means sur l'ensemble de ces descripteurs, avec un nombre de clusters K choisi proportionnellement à la durée du segment (ex. : 1 image-clef par tranche de 2 secondes, avec un minimum de 1 et un maximum plafonné). Pour chaque cluster, on sélectionne la trame la plus proche du centroïde comme image-clef représentative. K-Means est préférable ici car le nombre d'images-clefs souhaité est contrôlable et prévisible (on peut le fixer proportionnellement à la durée). DBSCAN, quant à lui, détermine automatiquement le nombre de clusters selon la densité, ce qui peut produire un nombre d'images-clefs imprévisible et inégal selon les segments.

Le regroupement est supérieur à une sélection naïve temporelle car la sélection naïve temporelle consiste à prendre une trame toutes les N trames (ex. : 1 trame par seconde). Cette approche présentera plusieurs failles importantes face à nos vidéos. Premièrement, l'approche naïve ignore le contenu visuel réel. Dans la première vidéo, une séquence de 5 secondes peut contenir 3 secondes d'une voiture en mouvement et 2 secondes d'un replay quasi-identique. Une sélection naïve pourrait retenir plusieurs trames redondantes du replay tout en manquant le moment le plus distinctif de la prise de vue. Deuxièmement, l'approche naïve est aveugle aux zones de faible variation. Dans le crawl Star Wars, les trames se ressemblent presque toutes. Une sélection naïve retient des images arbitraires sans garantir qu'elles capturent un état visuel unique ou significatif du segment. Troisièmement, l'approche naïve sur-représente les moments répétitifs. Une longue séquence sombre avec peu de mouvement produira de nombreuses trames quasi-identiques si l'on sélectionne naïvement. Le regroupement, lui, identifiera que ces trames appartiennent toutes au même cluster et n'en retiendra qu'une seule représentante.

Partie 2 — Implémentation Logicielle et Paramétrage

Question 3 : Développement de la Solution Adaptative (/6)

3.1 Architecture du pipeline

Le pipeline s'articule en quatre modules séquentiels. La lecture (OpenCV) charge les trames et les redimensionne à 320×180 . Ce lissage spatial réduit le bruit de compression et les artefacts de mouvement sub-pixel sans perdre l'information structurelle

nécessaire à la détection. Pour F1 et GoT, la lecture s'arrête à la dernière valeur de vérité terrain + 5s de marge (respectivement ~90s et ~50s). Star Wars est traité sur la vidéo complète, car elle ne contient qu'une seule vraie coupure à ~8s et le reste doit être analysé pour confirmer l'absence de transitions supplémentaires.

L'extraction de features calcule pour chaque paire de trames consécutives une distance χ^2 moyenne sur une grille 4×4 de blocs HSV normalisés, ce qui produit le signal de différence inter-trames. Le seuillage détecte les coupures selon deux stratégies : pour F1 et GoT, un seuil adaptatif causal (moyenne + $k \times \text{écart-type}$ sur les 50 trames précédentes) ; pour Star Wars, un seuil global au 99.5e percentile, adapté à la nature quasi-statique de cette vidéo où le seuil adaptatif échouait (le pic à 8s gonflait son propre seuil local). Les détections trop rapprochées sont fusionnées par un gap minimal (1.5s F1, 0.8s GoT, 2.5s Star Wars). Enfin, le clustering K-Means (scikit-learn) est appliqué sur les histogrammes HSV 3D de chaque prise de vue pour extraire les images-clefs, avec K proportionnel à la durée du segment (0.5 image/s, plafonné à 5).

3.2 Sensibilité aux seuils

Le paramètre central du pipeline est k , le multiplicateur de l'écart-type dans le seuil adaptatif ***mean + k × std***. Son effet est un compromis direct entre faux positifs et faux négatifs : un k trop bas laisse passer chaque pic de mouvement (voitures F1, overlays TV, flammes GoT) comme une coupure, multipliant les FP ; un k trop haut élève le seuil au-delà des transitions réelles de faible amplitude, produisant des FN. Pour F1, $k = 6.0$ a été retenu : la vidéo est très bruitée (mouvement extrême, incrustations graphiques) et un k plus bas noyait les vraies coupures dans le bruit. Pour GoT, $k = 4.0$ suffit car les transitions, bien que dans des scènes sombres, produisent des pics suffisamment marqués.

Le paramètre *MIN_GAP_SEC* (écart minimal entre deux coupures consécutives) a un impact similaire. Pour GoT, le réduire de 1.5s à 0.8s a permis de capturer les coupures très rapprochées à 23–24–25s, au prix de quelques FP supplémentaires. Trop grand, il fusionne des coupures légitimes ; trop petit, il laisse passer des doubles détections sur un même pic.

Pour Star Wars, le seuillage adaptatif échouait : l'unique pic réel à 9s gonflait sa propre fenêtre locale et s'effaçait progressivement. Un seuil global au 99.5e percentile a été substitué. Ce percentile positionne le seuil là où le pic de la vraie coupure (noir → logo) domine clairement le reste du signal, visible sur le signal de différence (voir Annexe A, Figure A3). Descendre à un percentile plus bas introduit plusieurs FP (dont le mouvement de caméra vers le soleil en fin de séquence) ; monter davantage risque de perdre le seul VP. Avec 99.5e, on obtient VP=1, FP=1, FN=0 : le FP résiduel étant inévitable sans classification sémantique du contenu.

Question 4 : Mosaïques et Performances (/3)

Les résultats de notre solution ont été évalués sur les trois vidéos en confrontant les coupures détectées à la vérité terrain avec une tolérance de $\pm 2s$. Le tableau ci-dessous présente les vrais positifs (VP), faux positifs (FP) et faux négatifs (FN) ainsi que les métriques de performance pour chaque vidéo. **Note** : précision = qualité des détections, rappel = exhaustivité, F-Score = compromis global.

	VP	FP	FN	Précision	Rappel	F-Score
Vidéo 1 — F1 Abu Dhabi	15	10	1	0.60	0.94	0.73
Vidéo 1 — Game of Thrones	16	3	2	0.84	0.89	0.86
Vidéo 3 — Star Wars	1	1	0	0.50	1.00	0.67

Les figures ci-dessous présentent les mosaïques d'images-clefs extraites automatiquement par K-Means (0.5 image-clef par seconde, maximum 5 par plan) sur la fenêtre d'évaluation de chaque vidéo, et non sur la totalité de celle-ci.



Figure 1 : Mosaïque des images-clefs extraites, vidéo F1 Abu Dhabi.




Figure 2 : Mosaïque des images-clefs extraites, vidéo Game of Thrones.



Figure 3 : Mosaïque des images-clefs extraites, vidéo Star Wars Opening Crawl.

Question 5 : Analyse Critique du Modèle (/3)

5.1 Évaluation globale

Le F-Score moyen sur les trois vidéos est de 0.75. La méthode performe le mieux sur GoT (F=0.86), où le seuillage adaptatif s'ajuste bien aux transitions marquées malgré l'obscurité. F1 obtient un bon rappel (0.94) mais une précision affaiblie (0.60) : le mouvement extrême des voitures et les incrustations graphiques génèrent des FP difficiles à éliminer sans augmenter k au point de manquer des vraies coupures. Star Wars obtient un rappel parfait (1.00) mais souffre d'un FP inévitable causé par le mouvement de caméra vers le soleil en fin de séquence.

5.2 Cas d'échec résiduels et incertitudes

Trois cas d'échec persistent malgré les optimisations. Premièrement, les incrustations graphiques de F1 (noms de pilotes, chrono, classement) génèrent des pics de différence localisés que le seuil adaptatif ne peut pas distinguer d'une vraie coupure sans information sémantique. Deuxièmement, les coupures très rapprochées de GoT (23s, 24s, 25s) restent à la limite du paramètre MIN_GAP_SEC : un ajustement de $\pm 0.1s$ peut fusionner ou diviser ces détections. Troisièmement, le K-Means sur histogrammes HSV produit des images-clefs redondantes dans les séquences à faible contraste comme GoT : des trames visuellement distinctes pour un observateur humain ont des histogrammes quasi-identiques dans le noir, ce qui amène le clustering à sélectionner des représentants similaires (voir mosaïque GoT, Figures 2 – KF8 et KF9).

5.3 Universalité du seuil et recommandations

Notre solution démontre qu'un seuil statique universel unique est impossible pour ces trois vidéos. En pratique, notre propre implémentation requiert des hyperparamètres distincts par vidéo ($k=6.0$ pour F1, $k=4.0$ pour GoT, percentile 99.5 pour Star Wars), ce qui confirme empiriquement cette limite (Yoo et al., 2006). Un algorithme véritablement universel nécessiterait une classification automatique du type de contenu pour sélectionner dynamiquement la stratégie de seuillage sans intervention humaine (Gonzalez & Woods). Pour aller au-delà des techniques du chapitre 5, deux pistes sont pertinentes : l'utilisation d'un réseau de neurones de détection de transitions tel que TransNetV2, qui gère nativement fondus, flashes et incrustations graphiques avec des performances de pointe sur plusieurs benchmarks (Souček & Lokoč, 2020) ; et l'intégration d'un descripteur temporel au vecteur de caractéristiques du K-Means pour forcer la diversité temporelle des images-clefs dans les segments à faible contraste visuel (Zhuang et al., 1998).

Références

Gonzalez, R.C. & Woods, R.E. *Digital Image Processing*. Pearson.

Yoo, H.W. et al. (2006). *Video scene change detection using the adaptive threshold*. Electronics Letters.

Zhuang, Y. et al. (1998). *Adaptive Key Frame Extraction Using Unsupervised Clustering*. IEEE ICIP.

Souček, T. & Lokoč, J. (2020). TransNet V2: An Effective Deep Network Architecture for Fast Shot Transition Detection. arXiv:2008.04838.

Pour code python :

- **OpenCV** : Bradski, G. (2000). *The OpenCV Library*. Dr. Dobb's Journal.
- **scikit-learn** : Pedregosa et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR 12, 2825-2830.

Annexe

Signal de distance χ^2 entre trames consécutives pour chaque vidéo :




Figure A1 : Signal de différence inter-trames, vidéo F1 Abu Dhabi.




Figure A2 : Signal de différence inter-trames, vidéo Game of Thrones S08E03.




Figure A3 : Signal de différence inter-trames, vidéo Star Wars Opening Crawl.